Домашнее задание №5

Page · Tag

Задание 1

С помощью SRA Explorer были скачаны файлы: ERR14230586 (813 Mb), ERR14230583 (322 Mb), ERR14230587 (929 Mb), ERR14230608 (378 Mb). Для запуска fastqc и multiqc было создано conda-окружение и скачаны соответствующие тулы. Далее был написан SLURM-скрипт для обработки скачанных файлов SRA.

Bash Unwrap Copy

```bash
#!/bin/bash

#SBATCH --job-name=fsatqc
#SBATCH --ntasks=1
#SBATCH --cpus-per-task=8
#SBATCH --mem=16G
#SBATCH --time=02:00:00
#SBATCH --output=/home/STUDY/FBMF/studfbmf02_10/hw5/fastqc%j.log
#SBATCH --partition=E5-2630-TITAN_X

BASE_DIR="$HOME/hw5"
DATA_DIR="${BASE_DIR}/data/raw"
SCRIPTS_DIR="${BASE_DIR}/scripts"
RESULTS_DIR="${BASE_DIR}/results"
FASTQC_DIR="${RESULTS_DIR}/fastqc"
MULTIQC_DIR="${RESULTS_DIR}/multiqc"
LOGS_DIR="${BASE_DIR}/logs"


mkdir -p "${DATA_DIR}" \
         "${SCRIPTS_DIR}" \
         "${FASTQC_DIR}" \
         "${MULTIQC_DIR}" \
         "${LOGS_DIR}"

cd "${DATA_DIR}"

curl -L
ftp://ftp.sra.ebi.ac.uk/vol1/fastq/ERR142/086/ERR14230586/ERR14230586.f
astq.gz -o ERR14230586_Illumina_HiSeq_4000_sequencing.fastq.gz
```

```
curl -L
ftp://ftp.sra.ebi.ac.uk/vol1/fastq/ERR142/083/ERR14230583/ERR14230583.f
astq.gz -o ERR14230583_Illumina_HiSeq_4000_sequencing.fastq.gz
curl -L
ftp://ftp.sra.ebi.ac.uk/vol1/fastq/ERR142/087/ERR14230587/ERR14230587.f
astq.gz -o ERR14230587_Illumina_HiSeq_4000_sequencing.fastq.gz
curl -L
ftp://ftp.sra.ebi.ac.uk/vol1/fastq/ERR142/008/ERR14230608/ERR14230608.f
astq.gz -o ERR14230608_Illumina_HiSeq_4000_sequencing.fastq.gz


FASTQ_FILES=("${DATA_DIR}"/*.fastq.gz)

fastqc "${FASTQ_FILES[@]}" --outdir "${FASTQC_DIR}" --extract 2>&1 |
tee "${LOGS_DIR}/fastqc.log"

multiqc \
    "${FASTQC_DIR}" \
    --outdir "${MULTIQC_DIR}" \
    --filename "multiqc_report_PRJEB84057" \
    --title "QC Report: PRJEB84057 (Illumina HiSeq 4000)" \
    --comment "Samples: ERR14230586, ERR14230583, ERR14230587,
ERR14230608" \
    2>&1 | tee "${LOGS_DIR}/multiqc.log"
```

В итоге был получен html-отчёт multiqc:

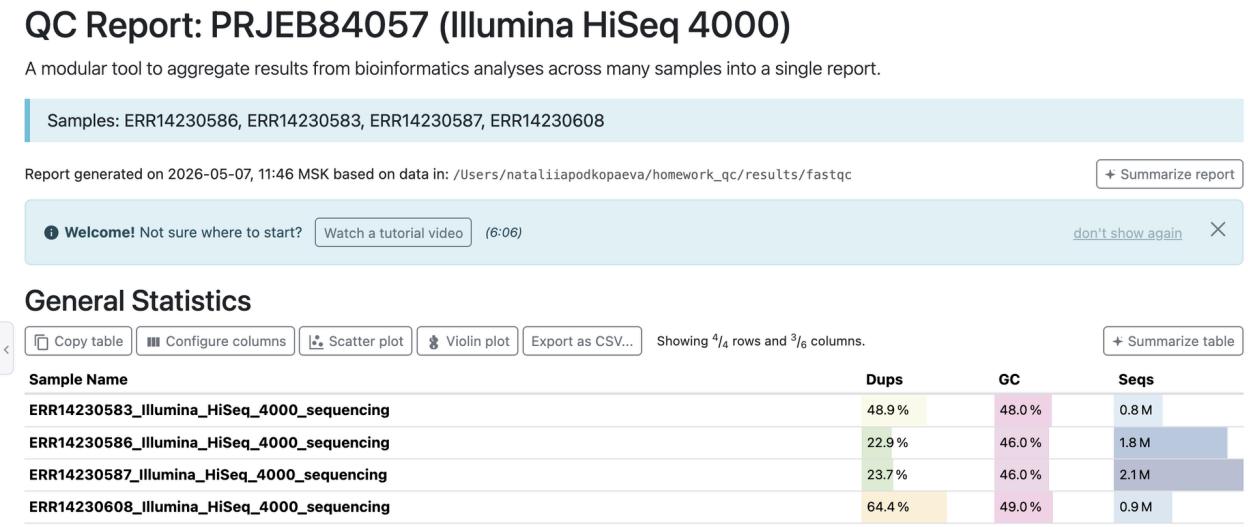

QC Report: PRJEB84057 (Illumina HiSeq 4000)

A modular tool to aggregate results from bioinformatics analyses across many samples into a single report.

Samples: ERR14230586, ERR14230583, ERR14230587, ERR14230608

Report generated on 2026-05-07, 11:46 MSK based on data in: /Users/nataliiapodkopaeva/homework_qc/results/fastqc

+ Summarize report

Welcome! Not sure where to start? Watch a tutorial video (6:06) don't show again

General Statistics

Copy table | Configure columns | Scatter plot | Violin plot | Export as CSV... Showing 4/4 rows and 3/6 columns. + Summarize table

Sample Name	Dups	GC	Seqs
ERR14230583_Illumina_HiSeq_4000_sequencing	48.9 %	48.0 %	0.8 M
ERR14230586_Illumina_HiSeq_4000_sequencing	22.9 %	46.0 %	1.8 M
ERR14230587_Illumina_HiSeq_4000_sequencing	23.7 %	46.0 %	2.1 M
ERR14230608_Illumina_HiSeq_4000_sequencing	64.4 %	49.0 %	0.9 M

Как можно видеть на картинке ниже, в двух из четырёх выбранных образцов большое количество оверпредставленных последовательностей. Также во всех образцах много дуплицированных последовательностей. В дальнейшем имеет смысл убрать дубликаты, если мы не проводим анализ дифференциальной экспрессии для получения чистых данных. Оверпредставленные последовательности могут почиститься после тримминга адаптеров.

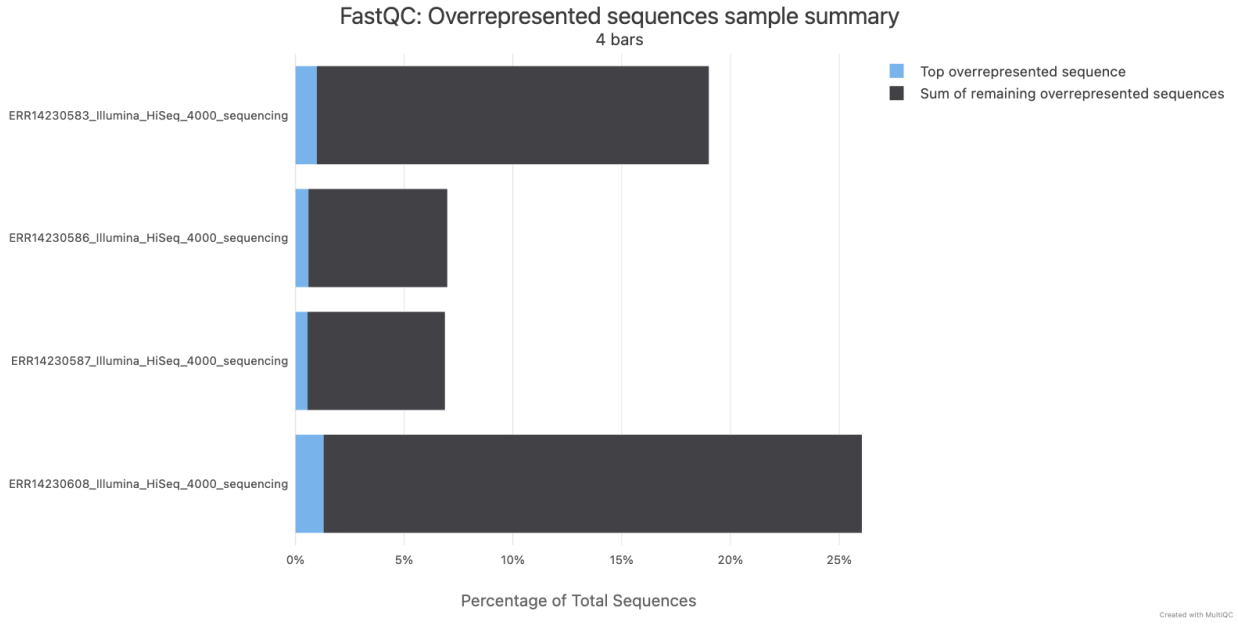

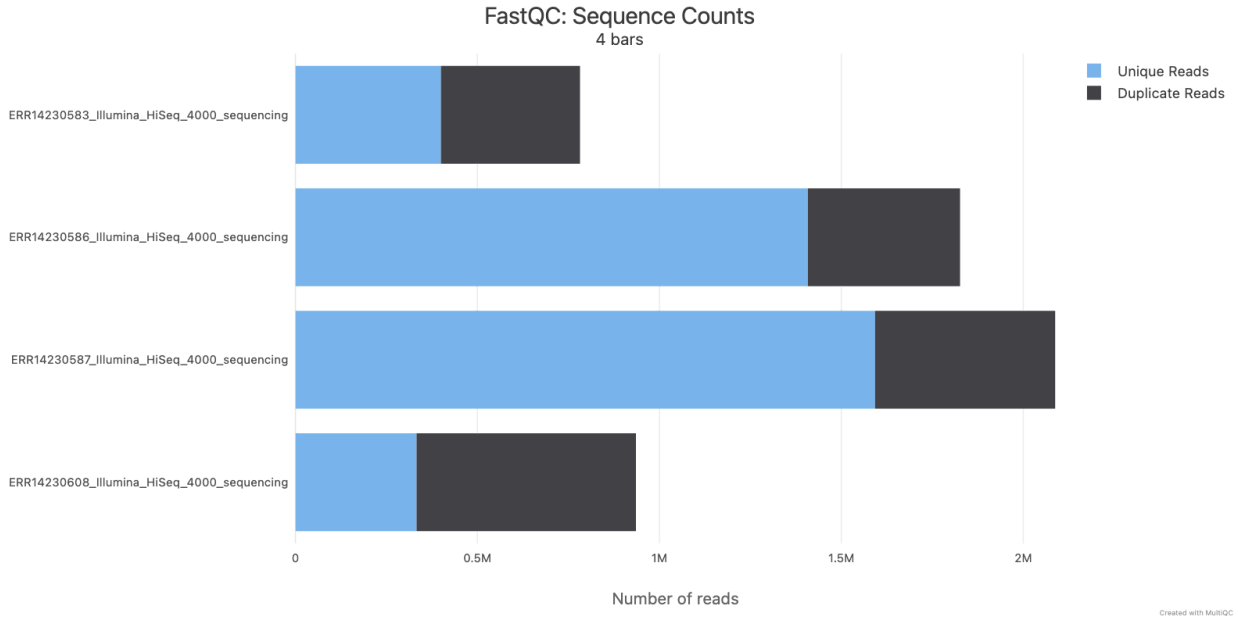

N в последовательностях очень мало, точность секвенирования высокая.

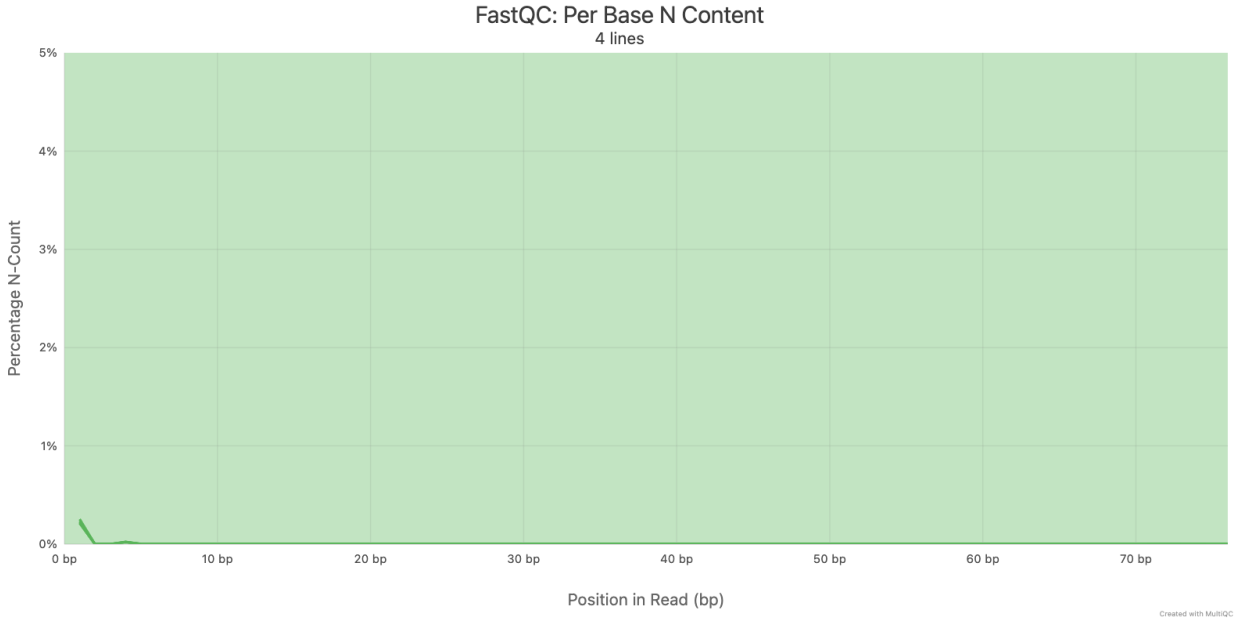

Phred-скоры также высокие для всех образцов (для всех позиций >30), наблюдается ухудшение качества на концах. В начале худшее качество вероятно связано с нестабильной интенсивностью сигнала в начале. На конце - с наличием адаптеров. Для улучшения скора адаптеры в дальнейшем обрежем и применим скользящее окно, чтобы убрать прочтения с плохим качеством.

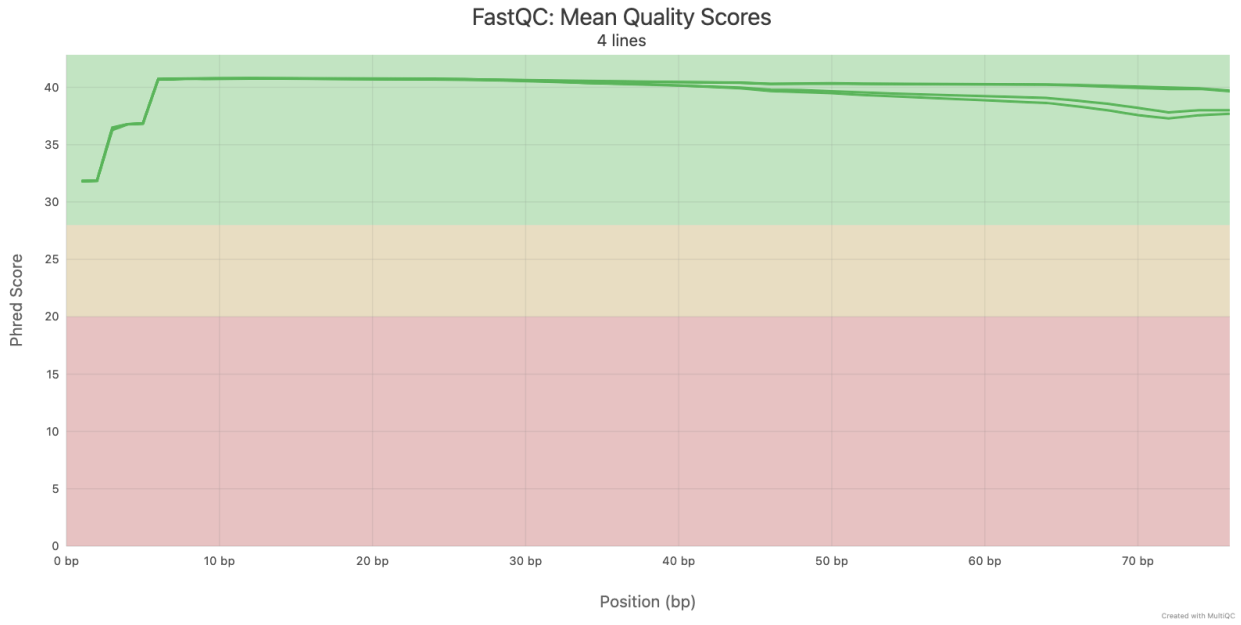

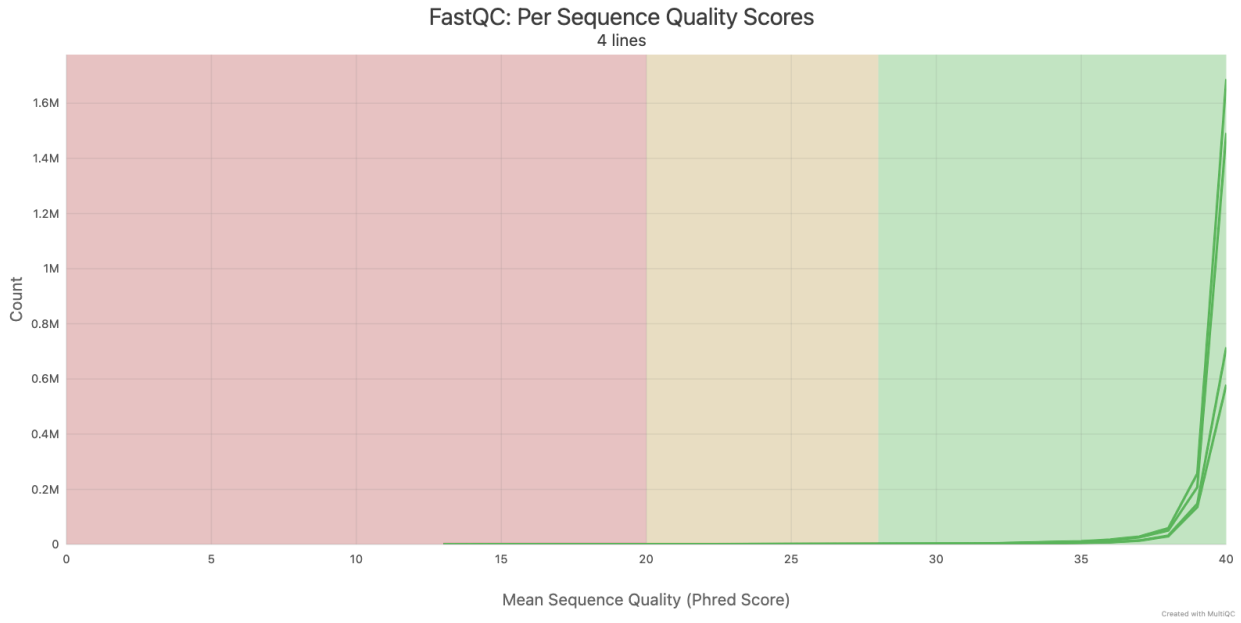

Длины последовательностей достаточно сильно варьируют (30-75 bp). Возможно после тримминга адаптеров длины станут более однородными. Однако вероятнее всего данные уже частично обработаны или это смешанные библиотеки. Имеется большое число коротких последовательностей (35-40 bp), что затруднит картирование на геном или сборку генома.

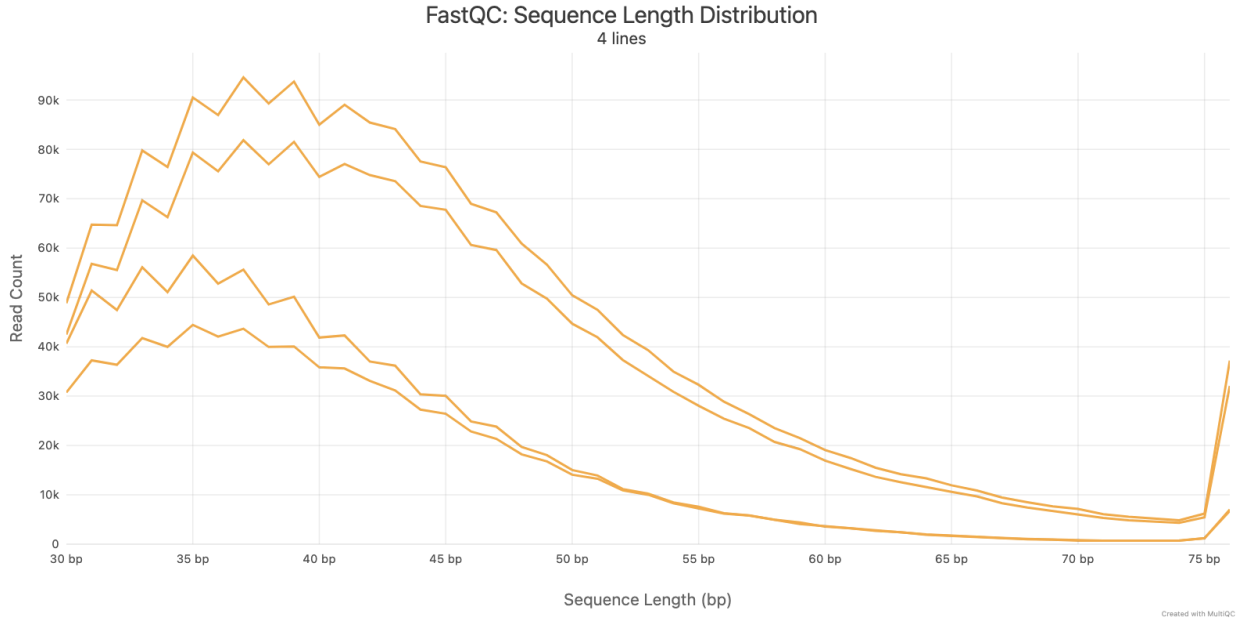

GC-контент тоже достаточно разнородный внутри одного образца, что может быть также связано с тем, что последовательности короткие и GC-состав сильно разнится между небольшими кусочками генома. Также может влиять наличие адаптеров, имеющих разный GC-контент.

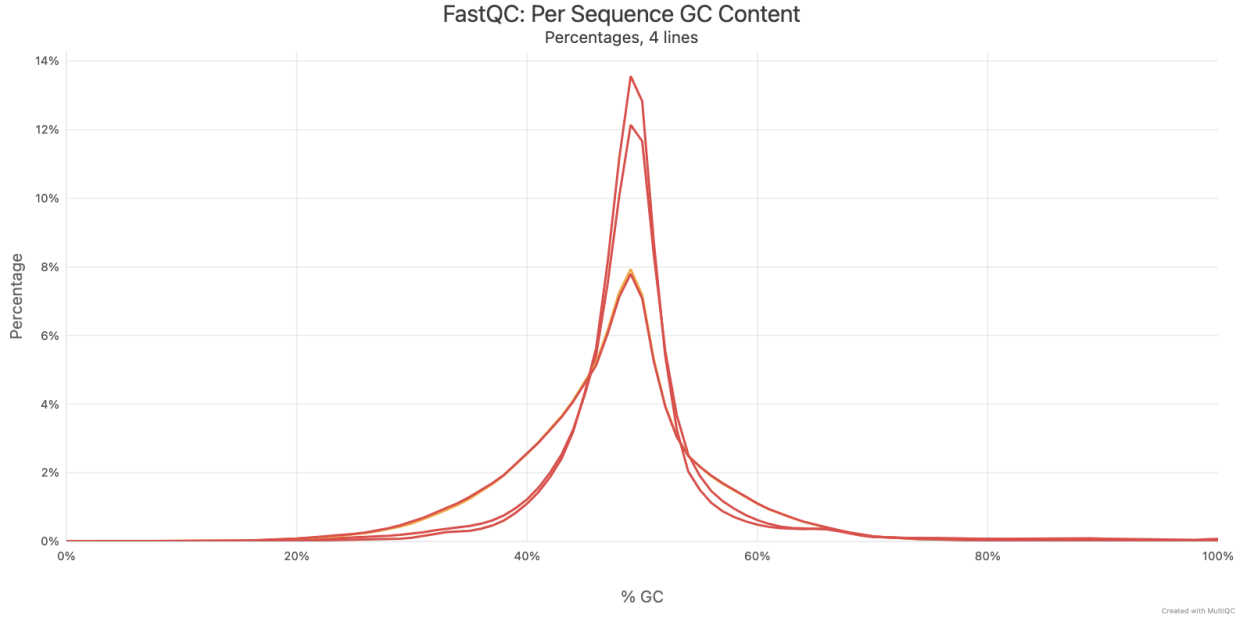

Задание 2

Далее проводилась фильтрация и обрезка ридов с помощью программы fastp. Были использованы следующие параметры:

- `--cut_right` - скользящее окно идёт слева направо
- `--cut_window_size 5` - размер окна 5 нуклеотидов
- `--cut_mean_quality 20` - обрезать если среднее качество в окне < 20
- `--length_required 36` - выбросить риды короче 36 bp

Bash

```bash
#!/bin/bash

#SBATCH --job-name=fsatqc
#SBATCH --ntasks=1
#SBATCH --cpus-per-task=8
#SBATCH --mem=16G
#SBATCH --time=02:00:00
#SBATCH --output=/home/STUDY/FBMF/studfbmf02_10/hw5/fastqc%j.log
#SBATCH --partition=E5-2630-TITAN_X

BASE_DIR="$HOME/hw5"
DATA_DIR="${BASE_DIR}/data/raw"
TRIMMED_DIR="${BASE_DIR}/data/trimmed"
FASTP_REPORTS_DIR="${BASE_DIR}/results/fastp"

mkdir -p "${TRIMMED_DIR}" "${FASTP_REPORTS_DIR}"

for INPUT in "${DATA_DIR}"/*.fastq.gz; do

    SAMPLE=$(basename "${INPUT}" .fastq.gz)

    fastp \
        -i "${INPUT}" \
        -o "${TRIMMED_DIR}/${SAMPLE}_trimmed.fastq.gz" \
        --cut_right \
        --cut_window_size 5 \
        --cut_mean_quality 20 \
        --length_required 36 \
        --thread 4 \
        --html "${FASTP_REPORTS_DIR}/${SAMPLE}_fastp.html" \
        --json "${FASTP_REPORTS_DIR}/${SAMPLE}_fastp.json" \
        2>&1 | tee "${LOGS_DIR}_fastp.log"

done
```

```
-rw-r--r--. 1 studfbmf02_10 fbmf 13585676 May  7 15:17 ERR14230583_Illumina_HiSeq_4000_sequencing_trimmed.fastq.gz
-rw-r--r--. 1 studfbmf02_10 fbmf 42965562 May  7 15:17 ERR14230586_Illumina_HiSeq_4000_sequencing_trimmed.fastq.gz
-rw-r--r--. 1 studfbmf02_10 fbmf 49220414 May  7 15:17 ERR14230587_Illumina_HiSeq_4000_sequencing_trimmed.fastq.gz
-rw-r--r--. 1 studfbmf02_10 fbmf 14376711 May  7 15:17 ERR14230608_Illumina_HiSeq_4000_sequencing_trimmed.fastq.gz
```

Образец	Ридов до	Ридов после	Отброшено	Q30 до	Q30 после	Дупликаты
ERR14230583	782,035	548,803	29.8%	98.78%	98.95%	46.5%
ERR14230586	1,826,305	1,450,141	20.6%	99.00%	99.17%	22.5%
ERR14230587	2,088,252	1,656,531	20.7%	99.02%	99.19%	23.5%
ERR14230608	935,637	627,377	32.9%	98.86%	99.03%	61.4%

Образец	Низкое качество	Короткие	Адаптеры	Прошли фильтр
ERR14230583	18 (0.002%)	233,214 (29.8%)	0	548,803 (70.2%)
ERR14230586	30 (0.002%)	376,134 (20.6%)	0	1,450,141 (79.4%)
ERR14230587	25 (0.001%)	431,696 (20.7%)	0	1,656,531 (79.3%)
ERR14230608	12 (0.001%)	308,248 (32.9%)	0	627,377 (67.1%)

Во всех образцах единственной значимой причиной отбраковки являлась недостаточная длина ридов после тримминга (меньше 36 нуклеотидов), тогда как потери по качеству и N-содержанию были пренебрежимо малы (< 0.01%). Адаптеры не обнаружены ни в одном образце, данные вероятно уже частично обработаны. После тримминга Q30 немного улучшился во всех образцах. ERR14230608 имеет самый высокий процент дупликатов (61.4%) и наибольшие потери из-за фильтра по длине (32.9%).

Есть ли в ваших данных адаптеры?
Адаптеры не обнаружены ни в одном из четырёх образцов - fastp не выявил их при auto-detection (`No adapter detected for read1`).

Есть ли участки с плохим качеством (Q<20) в конце ридов?
На графике FastQC Mean Quality Scores наблюдается незначительное снижение

качества на концах ридов (позиции 60–75 bp), однако все позиции остаются выше Q30. Тем не менее скользящее окно `SLIDINGWINDOW 5:20` было применено для удаления потенциально плохих концов и повышения общего качества данных.

Задание 3

Далее был проведён повторный контроль качества после fastp

```bash
#!/bin/bash

#SBATCH --job-name=fsatqc
#SBATCH --ntasks=1
#SBATCH --cpus-per-task=8
#SBATCH --mem=16G
#SBATCH --time=02:00:00
#SBATCH --output=/home/STUDY/FBMF/studfbmf02_10/hw5/fastqc%j.log
#SBATCH --partition=E5-2630-TITAN_X

BASE_DIR="$HOME/hw5"
TRIMMED_DIR="${BASE_DIR}/data/trimmed"
FASTQC_TRIMMED_DIR="${BASE_DIR}/results/fastqc_trimmed"
MULTIQC_TRIMMED_DIR="${BASE_DIR}/results/multiqc_trimmed"
LOGS_DIR="${BASE_DIR}/logs"

mkdir -p "${FASTQC_TRIMMED_DIR}" "${MULTIQC_TRIMMED_DIR}"

FASTQ_FILES=("${TRIMMED_DIR}"/*.fastq.gz)

fastqc "${FASTQ_FILES[@]}" \
    --outdir "${FASTQC_TRIMMED_DIR}" \
    --extract \
    --thread 4 \
    2>&1 | tee "${LOGS_DIR}/fastqc_trimmed.log"

multiqc \
    "${FASTQC_TRIMMED_DIR}" \
    --outdir "${MULTIQC_TRIMMED_DIR}" \
    --filename "multiqc_report_trimmed_PRJEB84057" \
    --title "QC Report after trimming: PRJEB84057 (Illumina HiSeq
4000)" \
    --comment "Samples after fastp trimming: ERR14230586, ERR14230583,
ERR14230587, ERR14230608" \
    2>&1 | tee "${LOGS_DIR}/multiqc_trimmed.log"
```

Уровень дупликатов снизился во всех образцах: ERR14230583: 48.9% → 42.0%, ERR14230586: 22.9% → 16.8%, ERR14230587: 23.7% → 17.9%, ERR14230608: 64.4% → 59.5%. Увеличилось процентное соотношение уникальных ридов, однако всё ещё осталось большое количество оверпредставленных последовательностей, которые не являются адаптерами.

QC Report after trimming: PRJEB84057 (Illumina HiSeq 4000)

A modular tool to aggregate results from bioinformatics analyses across many samples into a single report.

Samples after fastp trimming: ERR14230586, ERR14230583, ERR14230587, ERR14230608

Report generated on 2026-05-07, 14:47 MSK based on data in: `/Users/nataliiapodkopaeva/homework_qc/results/fastqc_trimmed`

+ Summarize report

Welcome! Not sure where to start? Watch a tutorial video *(6:06)*

don't show again

General Statistics

Copy table | Configure columns | Scatter plot | Violin plot | Export as CSV... | Showing 4/4 rows and 3/6 columns. | + Summarize table

Sample Name	Dups	GC	Seqs
ERR14230583_Illumina_HiSeq_4000_sequencing	42.0 %	48.0 %	0.5 M
ERR14230586_Illumina_HiSeq_4000_sequencing	16.8 %	46.0 %	1.5 M
ERR14230587_Illumina_HiSeq_4000_sequencing	17.9 %	46.0 %	1.7 M
ERR14230608_Illumina_HiSeq_4000_sequencing	59.5 %	48.0 %	0.6 M

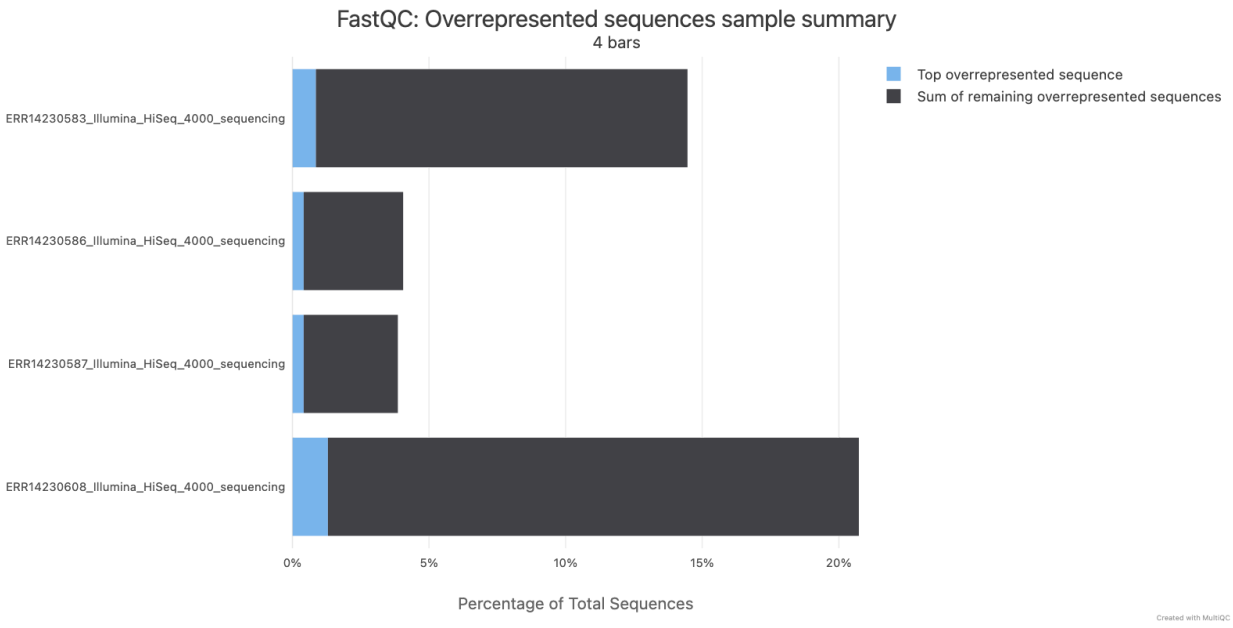

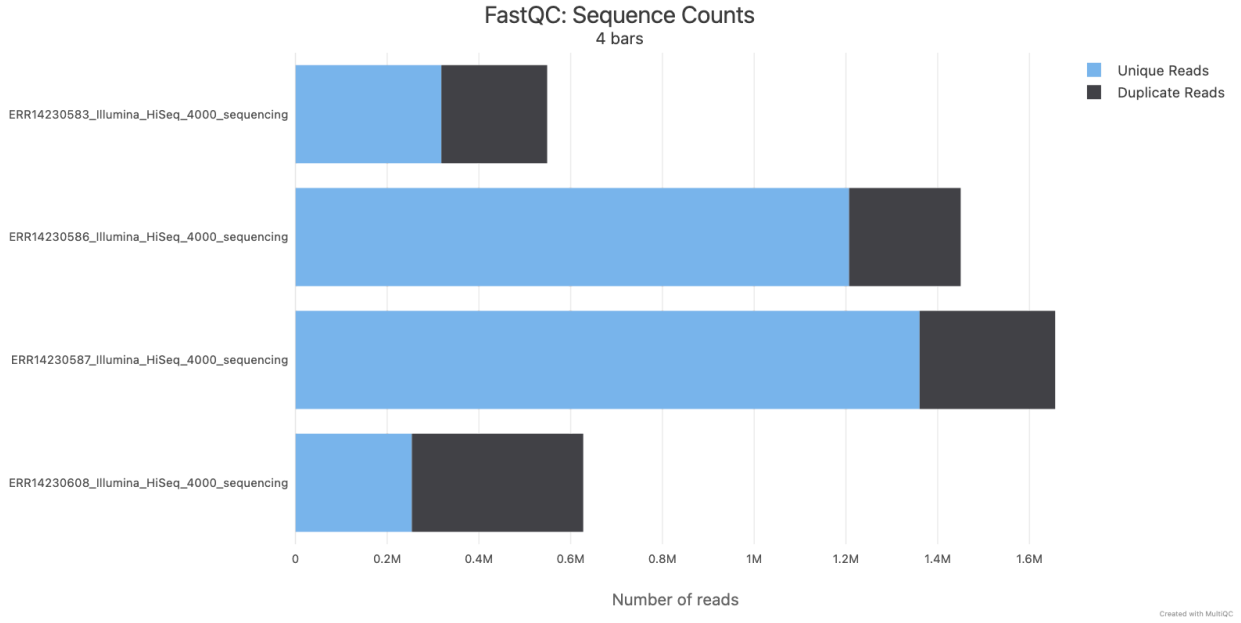

Phred scores незначительно улучшилось во всех образцах, Q30 вырос на ~0.2% в каждом образце за счёт обрезки низкокачественных концов скользящим окном. Минимальное среднее качество последовательности возросло с 15 до 23. Вид Phred score в начале не изменился, так как fastp не трогал начало ридов (`--cut_right` работает только справа).

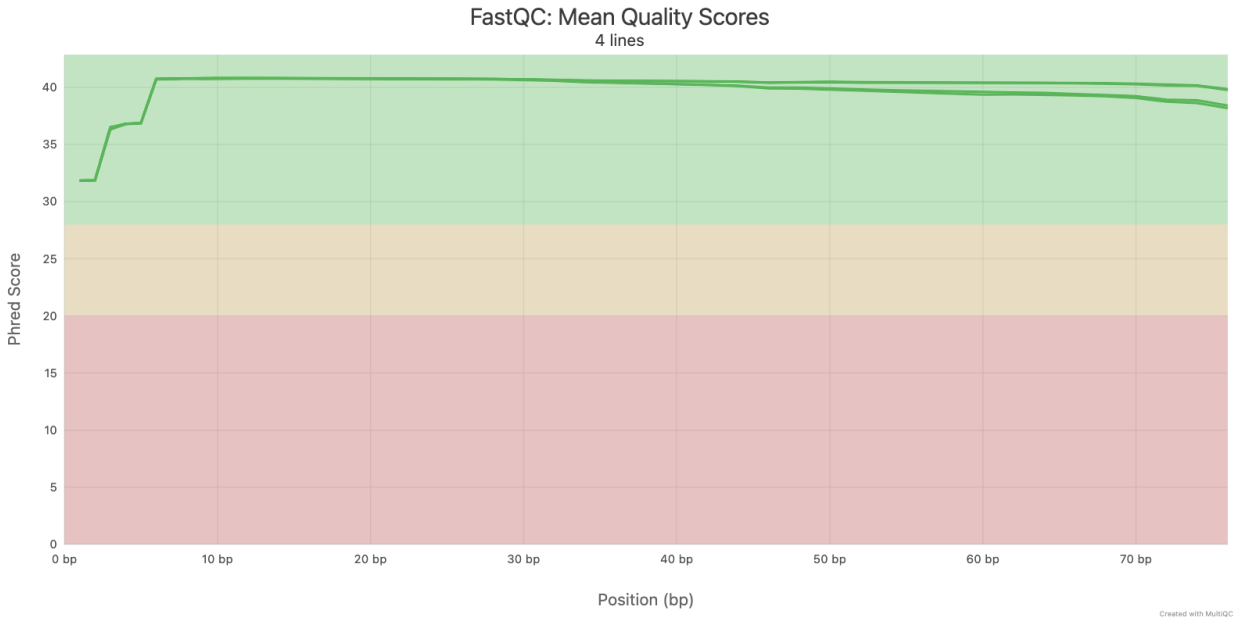

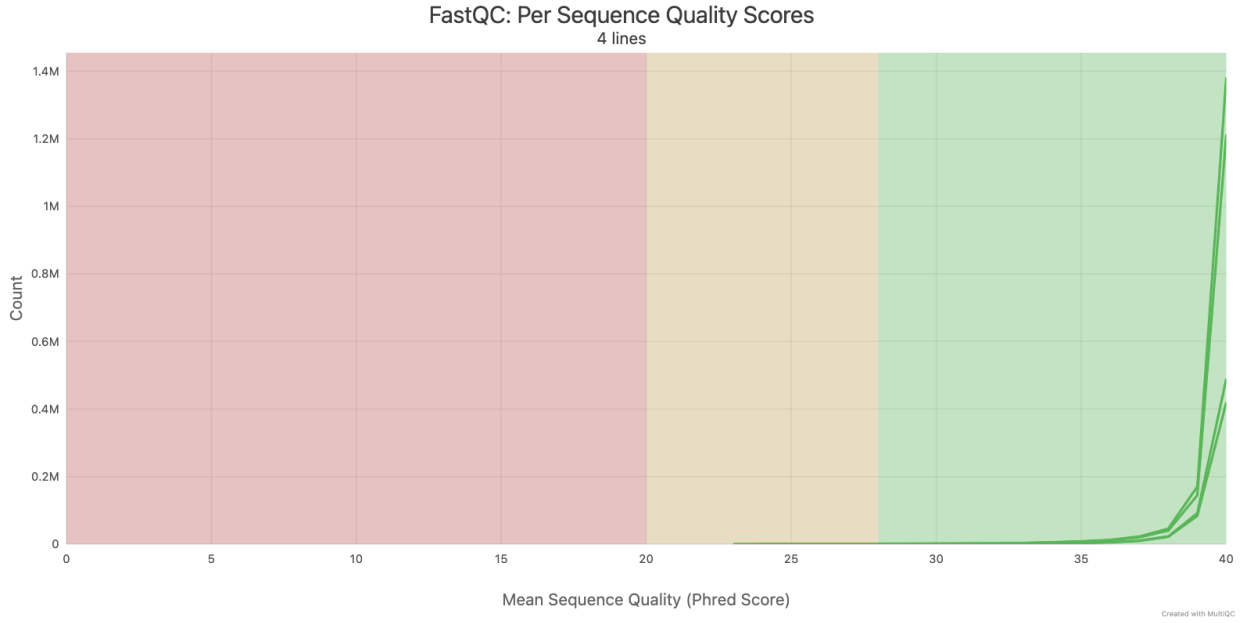

GC-контент почти не изменился, так как адаптеров обнаружено не было и в таком случае GC-состав является биологическим свойством образца, а не артефактом качества.

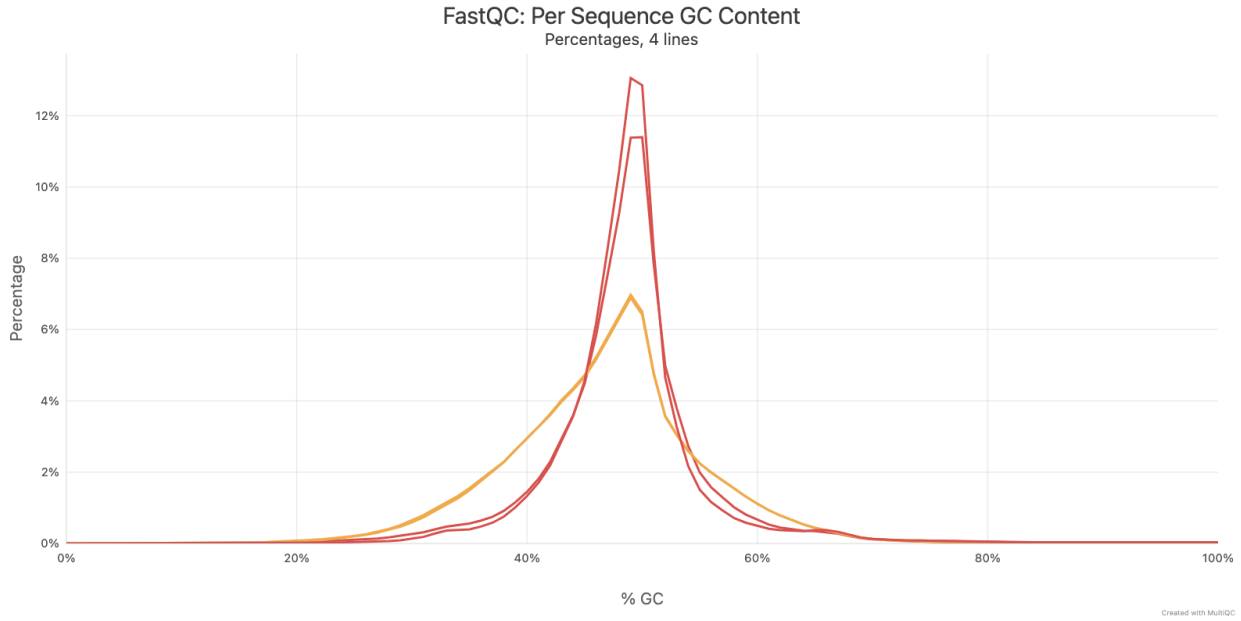

Минимальная длина теперь 36 bp вместо 30 bp, что соответствует установленному фильтру `--length_required 36`. Короткие риды полностью убраны, распределение сдвинулось вправо.

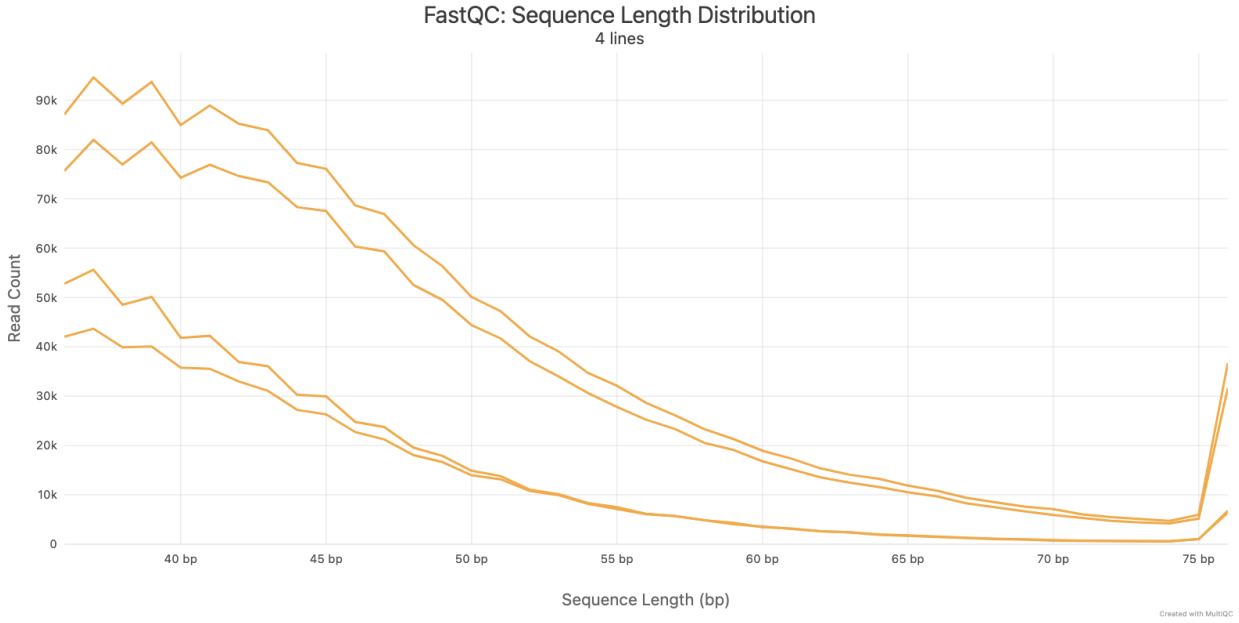

В ходе выполнения работы был проведён контроль качества данных из проекта PRJEB84057. Исходные данные оказались высокого качества: Phred-скоры >30 для всех позиций, минимальное количество N-содержащих ридов. Адаптеры не были обнаружены, что свидетельствует о предварительной обработке данных.

Основной проблемой стало большое количество коротких ридов (30–35 bp) и высокий уровень дупликатов в образцах ERR14230583 (46.5%) и ERR14230608 (61.4%). После тримминга с помощью fastp короткие риды были отброшены, что привело к потере 20–33% ридов в зависимости от образца. Качество оставшихся ридов незначительно улучшилось: Q30 вырос на ~0.2%, уровень дупликатов снизился на 4–6%. Оверпредставленные последовательности сохранились после тримминга, так как они не являются адаптерами, и их природа требует дополнительного исследования.

Данные после тримминга пригодны для дальнейшего анализа, однако наличие оверпредставленных последовательностей и высокий уровень дупликатов в части образцов следует учитывать при интерпретации результатов.