Домашнее задание №6

Page · Tag

Задание 1

Была проведена оценка качества секвенирования для файлов Eg_Treg_S71_R1_001.fastq.gz и Eg_Treg_S71_R2_001.fastq.gz с помощью fastqc и multiqc до какой-либо фильрации и обработки. Для проведения анализа использовался bash-скрипт (fastqc.sh на гитхаб).

Как можно видеть, качество и точность секвенирования высокие. Процент N очень низкий, Phred Score во всех позициях выше 30. Однако имеются последовательности адаптеров, которые необходимо обрезать для дальнейшего анализа. Так как будем картировать на геном, последовательности адаптеров будут сильно мешать, так как они являются синтетическими.

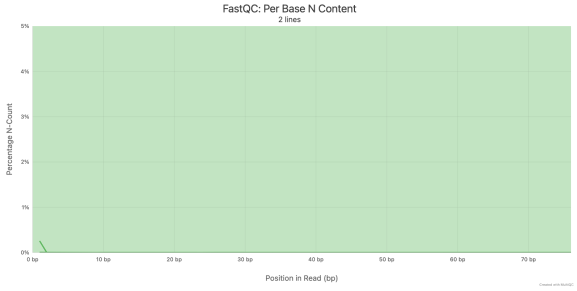

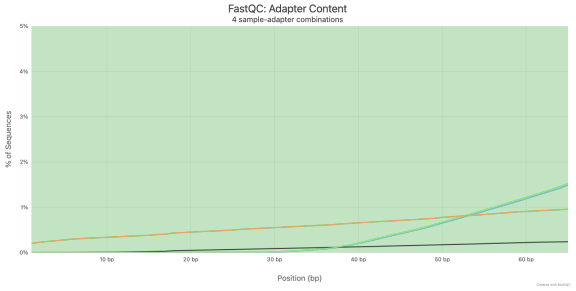

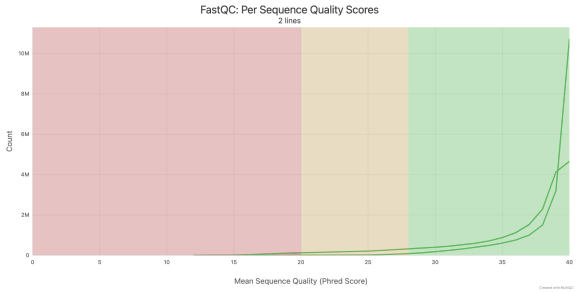

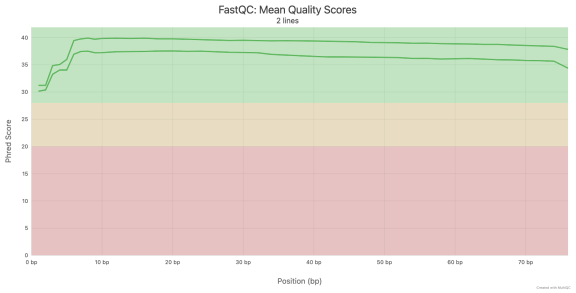

Также видно, что есть последовательности-дупликаты и большой процент оверпредставленных последовательностей в одном из образцов. Возможно эти последовательности также являются адаптерами.

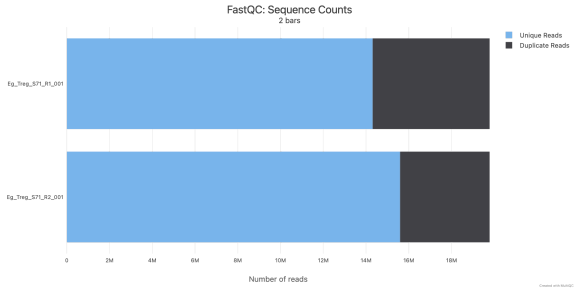

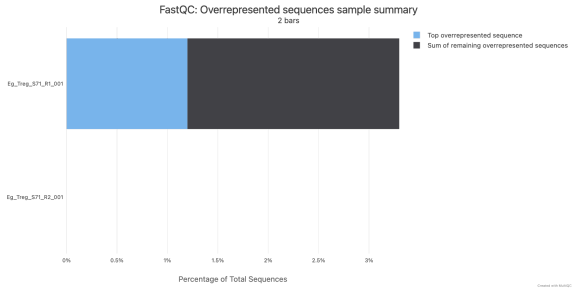

GC-состав не имеет характерной гауссовской формы, возможно также из-за наличия синтетических адаптеров.

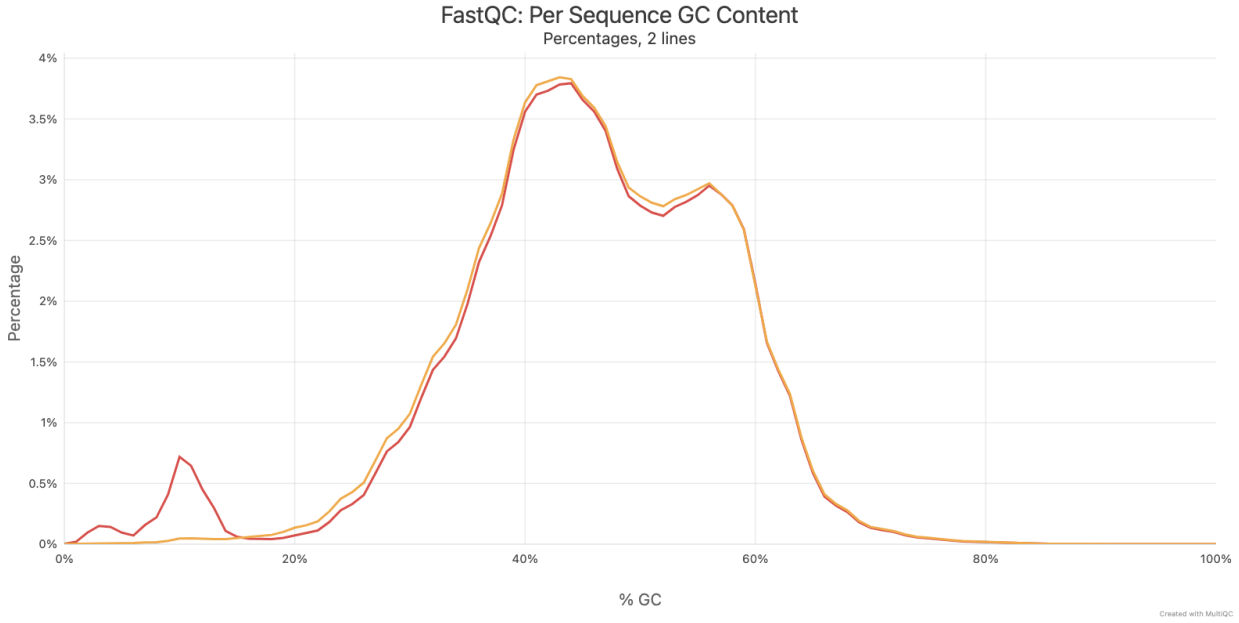

Есть ли в ваших данных адаптеры? Да, есть, попробуем их далее удалить

Есть ли участки с плохим качеством (Q<20) в конце ридов? Нет, качество хорошее на всех позициях (>30)

Задание 2

Проведём тримминг с помощью fastp (скрипт fastp.sh на гитхаб) и посмотрим на качество после него (скрипт fastqc_trimmed.sh на гитхаб).

После обработки видим заметное уменьшение числа адаптеров. На графике Adapter Content до обработки были видны нарастающие кривые к концу ридов (до ~2%), после тримминга они практически исчезли. Длина ридов после тримминга почти одинакова у всех последовательностей (виден узкий пик у 75 bp).

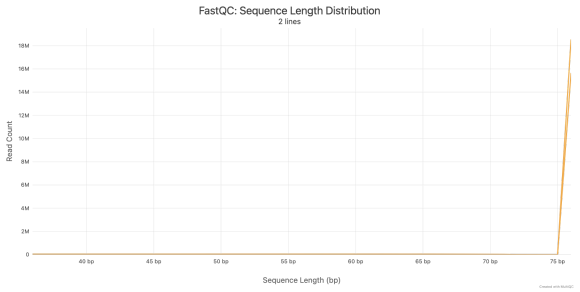

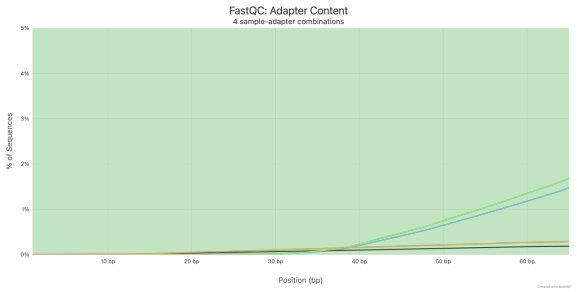

Оверпредставленные последовательности у образца R1 они заметно сократились (тёмный сегмент на графике уменьшился), что подтверждает предположение о том, что они были адаптерами.

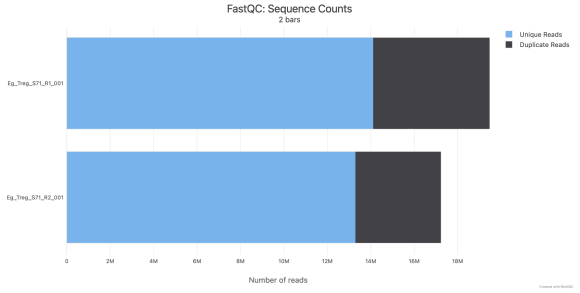

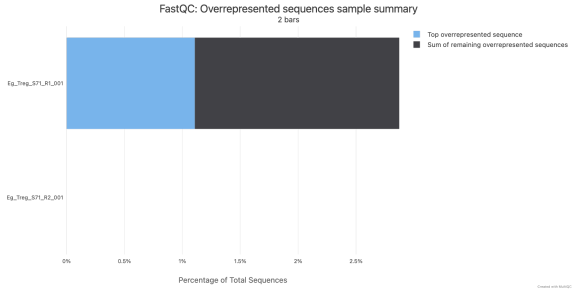

Качество ридов осталось стабильно высоким, выше 30 на всех позициях, что и ожидалось, поскольку изначальное качество было хорошим.

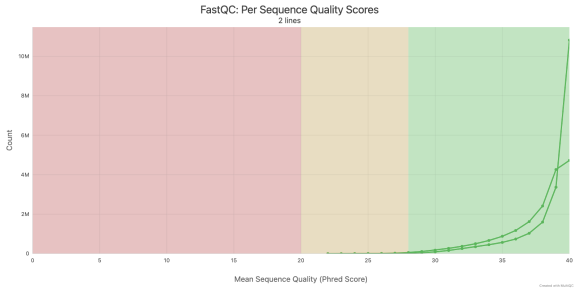

GC-состав немного улучшился, после обработки кривая стала чуть более симметричной, хотя двугорбый характер сохранился. Первый небольшой пик в районе 0–20% GC стал менее выраженным.

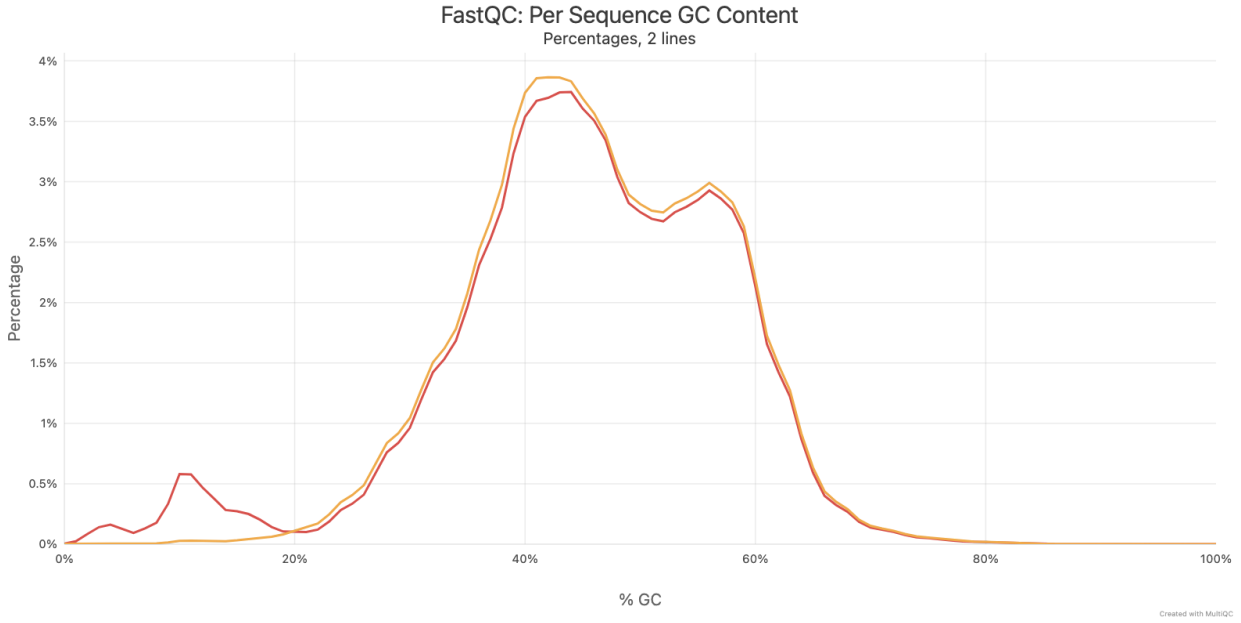

Для дальнейшего картирования на геном будем использовать обрезанные риды, чтобы не картировать адаптеры.

Задание 3

Проведём выравнивание ридов на референсный геном GRCh38 с помощью STAR. Референсный геном в общей папке /home/STUDY/FBMF/bioinformatics/GRCh38/ оказался недоступен для чтения. Поэтому референс был скачан самостоятельно с Ensembl (release 110) и индекс построен локально (скрипт download.sh на гитхаб). Далее было проведено выравнивание STAR (скрипт star.sh на гитхаб).

```
-rw-r--r--. 1 studfbmf02_10 fbmf 1876318448 May  8 19:36 RNA_Aligned.sortedByCoord.out.bam
-rw-r--r--. 1 studfbmf02_10 fbmf       2028 May  8 19:36 RNA_Log.final.out
-rw-r--r--. 1 studfbmf02_10 fbmf      14384 May  8 19:36 RNA_Log.out
-rw-r--r--. 1 studfbmf02_10 fbmf       1426 May  8 19:36 RNA_Log.progress.out
-rw-r--r--. 1 studfbmf02_10 fbmf    1444726 May  8 19:36 RNA_ReadsPerGene.out.tab
-rw-r--r--. 1 studfbmf02_10 fbmf    4438502 May  8 19:36 RNA_SJ.out.tab
```

Результаты выравнивания STAR:

- Всего ридов: 16 972 983
- Уникально выровнено: 14 495 041 (85.40%)
- Мультимапперы: 6.08%
- Не выровнено (слишком короткие): 7.86%
- Процент сплайсов с аннотацией (GT/AG): 95.7%
- Химерных ридов: 0%

Результаты выравнивания выглядят хорошо: 85.4% уникально выровненных ридов - нормальный показатель для RNA-seq данных человека. Мультимапперов немного (6%), но они ожидаемы из-за повторяющихся элементов генома. Почти 8% коротких невыровненных ридов следствие тримминга, часть ридов после обрезки адаптеров стала слишком короткой для

маппинга. Высокий процент канонических сплайсов GT/AG (95.7%) подтверждает что выравнивание прошло корректно и риды действительно происходят из мРНК.

Далее проводлилась сборка транскриптов (StringTie, de novo режим, скрипт stringtie.sh на гитхаб). StringTie запущен в режиме de novo без референсной аннотации, что позволяет обнаружить транскрипты, отсутствующие в базах данных.

```
drwxr-xr-x. 2 studfbmf02_10 fbmf         1 May  9 10:28 .
drwxr-xr-x. 8 studfbmf02_10 fbmf        31 May  9 12:55 ..
-rw-r--r--. 1 studfbmf02_10 fbmf 21742294 May  9 10:28 transcripts.gtf
```

Результаты StringTie:

Всего транскриптов: 154 404

```
1	StringTie	transcript	75900	77171	1000	.	.	gene_id "STRG.1"; transcript_id "STRG.1.1"; cov "4.996384"; FPKM "2.201654"; TPM "5.034880";
1	StringTie	exon	75900	77171	1000	.	.	gene_id "STRG.1"; transcript_id "STRG.1.1"; exon_number "1"; cov "4.996384";
1	StringTie	transcript	91658	92659	1000	.	.	gene_id "STRG.2"; transcript_id "STRG.2.1"; cov "7.886688"; FPKM "3.475265"; TPM "7.947452";
1	StringTie	exon	91658	92659	1000	.	.	gene_id "STRG.2"; transcript_id "STRG.2.1"; exon_number "1"; cov "7.886688";
1	StringTie	transcript	99122	101672	1000	.	.	gene_id "STRG.3"; transcript_id "STRG.3.1"; cov "4.973078"; FPKM "2.191384"; TPM "5.011394";
1	StringTie	exon	99122	101672	1000	.	.	gene_id "STRG.3"; transcript_id "STRG.3.1"; exon_number "1"; cov "4.973078";
1	StringTie	transcript	266254	269231	1000	.	.	gene_id "STRG.4"; transcript_id "STRG.4.1"; cov "9.294345"; FPKM "4.095548"; TPM "9.365954";
1	StringTie	exon	266254	269231	1000	.	.	gene_id "STRG.4"; transcript_id "STRG.4.1"; exon_number "1"; cov "9.294345";
1	StringTie	transcript	275677	278632	1000	.	.	gene_id "STRG.5"; transcript_id "STRG.5.1"; cov "4.905226"; FPKM "2.161485"; TPM "4.943019";
1	StringTie	exon	275677	278632	1000	.	.	gene_id "STRG.5"; transcript_id "STRG.5.1"; exon_number "1"; cov "4.905226";
```

Поле	Пример	Описание
chrom	1	Хромосома
source	StringTie	Программа
type	transcript / exon	Тип записи
start	75900	Начало
end	77171	Конец
score	1000	Оценка качества
strand	.	Цепь
frame	.	Рамка считывания
attributes	gene_id "STRG.1"; transcript_id "STRG.1.1"; cov "4.99"; FPKM "2.20"; TPM "5.03"	Метаданные

StringTie собирает транскрипты непосредственно из выровненных ридов, не опираясь на референсную аннотацию (de novo режим). Это позволяет обнаруживать новые изоформы и транскрипты, отсутствующие в базах данных. Файл transcripts.gtf полезен для:

- подсчёта экспрессии генов и транскриптов (значения TPM и FPKM уже содержатся в файле)
- дифференциального анализа экспрессии через DESeq2 или edgeR
- аннотации новых транскриптов и изоформ в малоизученных тканях
- сравнения транскриптома образца с референсной аннотацией

Задание 4

Выравнивание HTSeq

Сделаем выравнивание ридов на референсный геном GRCh38 с помощью HTSeq (скрипт htseq.sh на гитхаб).

```
-rw-r--r--.  1 studfbmf02_10 fbmf       1155138 May  9 13:12  htseq_counts.txt
```

Всего уникальных генов в htseq_counts.txt: 62 754.

Статистика:

Метка	Количество ридов	Описание
__no_feature	11 106 927	Не попали ни в один ген (интроны, межгенные области)
__ambiguous	561 235	Перекрываются несколько генов
__too_low_aQual	0	Слишком низкое качество выравнивания
__not_aligned	0	Не выровнены
__alignment_not_unique	1 032 316	Мультимапперы

Большое количество __no_feature (11 млн) объясняется тем, что RNA-seq риды попадают в интроны и межгенные области, которые не аннотированы как экзоны. Число мультимапперов (1 032 316) совпадает с данными STAR, что логично - это одни и те же риды, просто HTSeq их отбросил.

Сравнение каунтов STAR и HTSeq

Для сравнения были взяты гены с ненулевыми каунтами в обоих методах (n = 34 818 генов). Значения были логарифмированы (log10) для наглядности. Ниже приведён график корреляции Пирсона для каунтов из двух методов. Pearson r = 0.9455, p ≈ 0 - очень высокая корреляция между двумя методами.

Почему результаты могут не совпадать?

Корреляция высокая, но не идеальная — это ожидаемо, потому что методы считают по-разному. STAR использует свою внутреннюю логику подсчёта, а HTSeq явно проверяет пересечение рида с экзонами из GTF. Мультимапперы тоже обрабатываются по-разному: HTSeq их просто выбрасывает (видно в __alignment_not_unique), а STAR может часть учитывать. Также, я сравнивала колонку forward из STAR, но если библиотека нестрендованная, то правильнее была бы колонка unstranded, и цифры бы немного отличались.

Что использовать для DE-анализа?

Я бы выбрала каунты STAR, они получаются сразу в процессе выравнивания, не нужно гонять отдельный инструмент. HTSeq также работает значительно дольше на тех же данных. По сути для DESeq2 или edgeR разницы нет, оба дают сырые целочисленные каунты, которые эти инструменты и ожидают на входе.