Домашнее задание №7

Page · Tag

Задание 1

Нормализация

В этом задании мы делаем анализ дифференциальной экспрессии для образцов клеток из 4х разных клеточных линий колоректального рака (HCT-15, HCT-116, SW620 и SW837). Таким образом мы пытаемся определить, какие гены оверэкспрессированы или наоборот имеют пониженный уровень экспрессии в данных образцах. Наши данные представляют собой RNA-Seq каунты, то есть для каждого гена подсчитывается число прочтений мРНК, которое было секвенировано. Такие "сырые" каунты необходимо для начала нормировать, так как полученные данные могут сильно зависеть от протокола секвенирования, а экспрессия гена может также сильно варьировать в зависимости от длины гена.

Поэтому первым делом мы делаем нормализацию TPM:

Шаг 1: делим на длину гена (в килобазах)

$$RPK_i = \frac{\text{counts}_i}{\text{length}_i} \times 10^3$$

Шаг 2: делим на сумму всех RPK в образце и умножаем на миллион:

$$TPM_i = \frac{RPK_i}{\sum_j RPK_j} \times 10^6$$

После проведения нормализации нам необходимо провести PCA, чтобы убедиться, что различия между образцами связаны с различиями между самими клетками, а не с тем, например, что часть образцов взята у пациентов-женщин, а другая - у мужчин. Для этого мы делаем PCA и ожидаем, что у нас образуются кластеры образцов из одинаковых клеточных линий. В нашем случае график PCA выглядит вот так:

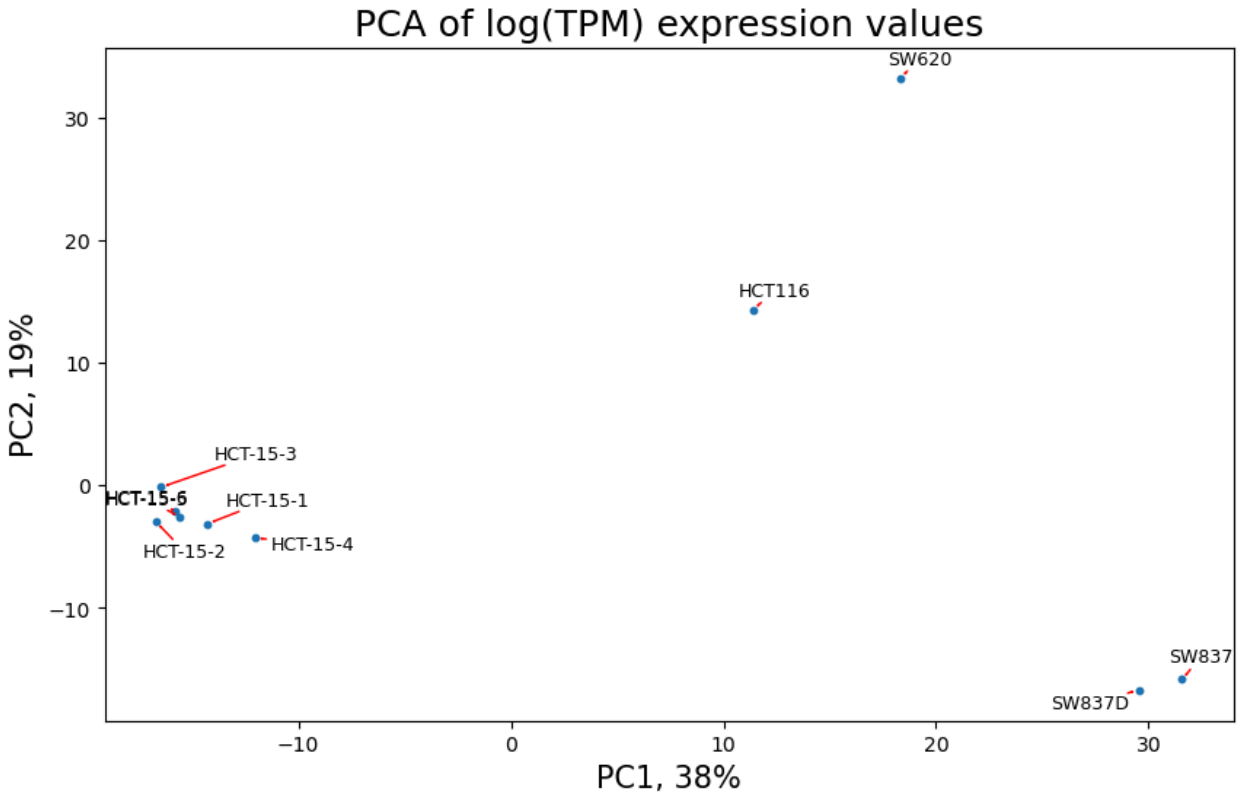

Как можно заметить, образцы HCT-15 образовали один кластер, также близко расположились два образца SW837. Признаков batch-эффекта не наблюдается, образцы HCT-15 кластеризуются компактно независимо от порядка секвенирования. Образцы HCT116 и SW620 получились более обособленные. Это может быть связано как и с тем, что эти клеточные линии сильно отличаются от двух других, так и с тем, что они были получены в каких-то других условиях (другой пациент, другая среда и т.д.). Так как для этих клеточных линий имеется по одному образцу, то точно сказать нельзя. Поэтому эти образцы имело бы смысл исключить из анализа и продолжать его только для HCT-15 и/или SW837, что и было сделано.

Clustermap: корреляции Пирсона между образцами

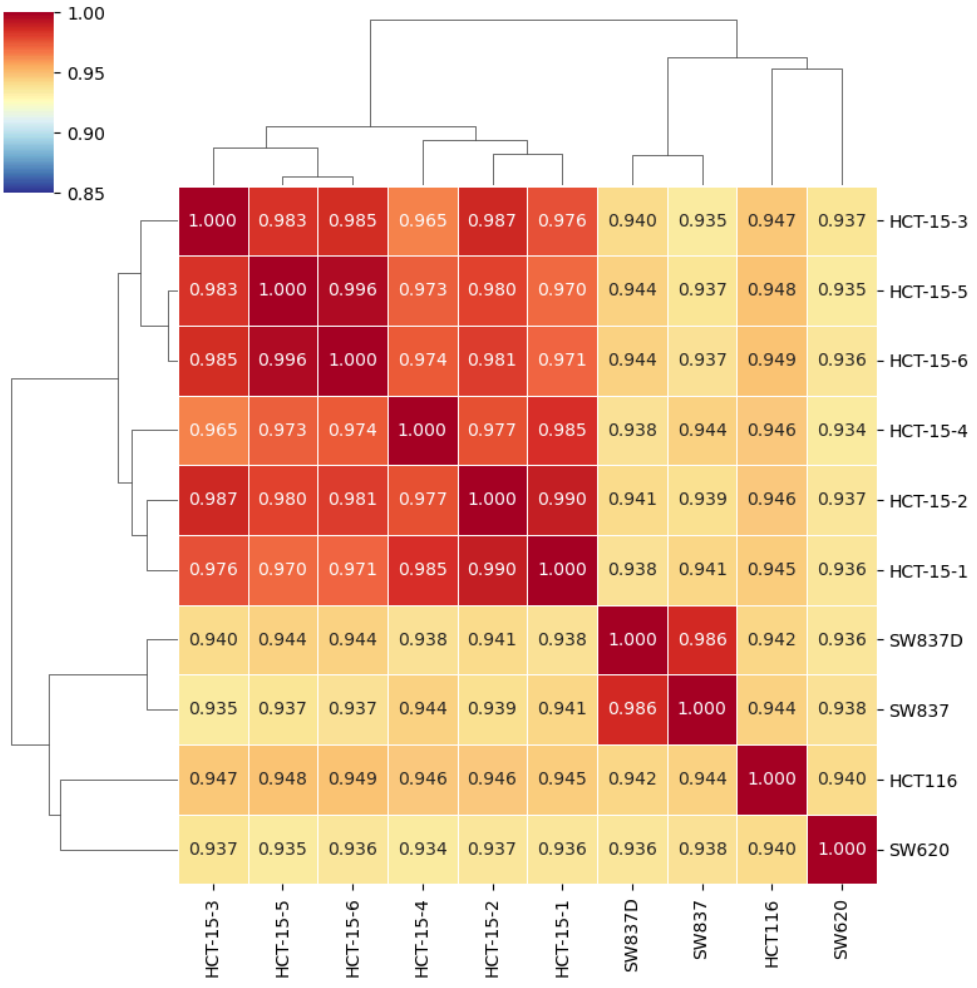

Также был построен heatmap корреляции Пирсона между образцами. Как можно видеть, наибольшая корреляция наблюдается для образцов HCT-15 и SW837 между собой. Корреляция HCT-16 больше с образцами HCT-15, чем с SW, а у SW620 - наибольшая корреляция с HCT-16.

DESeq2

В исходном датасете представлены образцы четырёх клеточных линий колоректального рака: HCT-15 (6 образцов: 3 контрольных - HCT_WT1/2/3, и 3 эксперимента - R1-1/2/3), SW837 (2 образца), HCT116 (1 образец) и SW620 (1 образец).

Для анализа дифференциальной экспрессии необходимо попарное сравнение двух групп. Осмысленное сравнение возможно только для линии HCT-15: здесь есть две группы с тремя повторностями в каждой: контроль (WT) и опыт (R1). Остальные линии (SW837, HCT116, SW620) представляют собой биологически независимые объекты с принципиально другим генетическим фоном, поэтому их прямое сравнение с HCT-15 некорректно без специального дизайна эксперимента. Дополнительно, на графике PCA образцы HCT116 и SW620

оказались сильно обособлены от остальных, а SW837 и SW620 представлены недостаточным числом реплик (2 образца), что делает статистическую оценку вариабельности ненадёжной. По этим причинам из дальнейшего анализа были исключены образцы SW837, HCT116 и SW620. Анализ дифференциальной экспрессии проводился только на образцах клеточной линии HCT-15: WT (контроль) vs R1 (опыт).

После запуска R-скрипта для анализа дифференциальной экспрессии была получена таблица с p value и fold change (differential_expression_results.csv на гитхаб) и следующий volcano-plot:

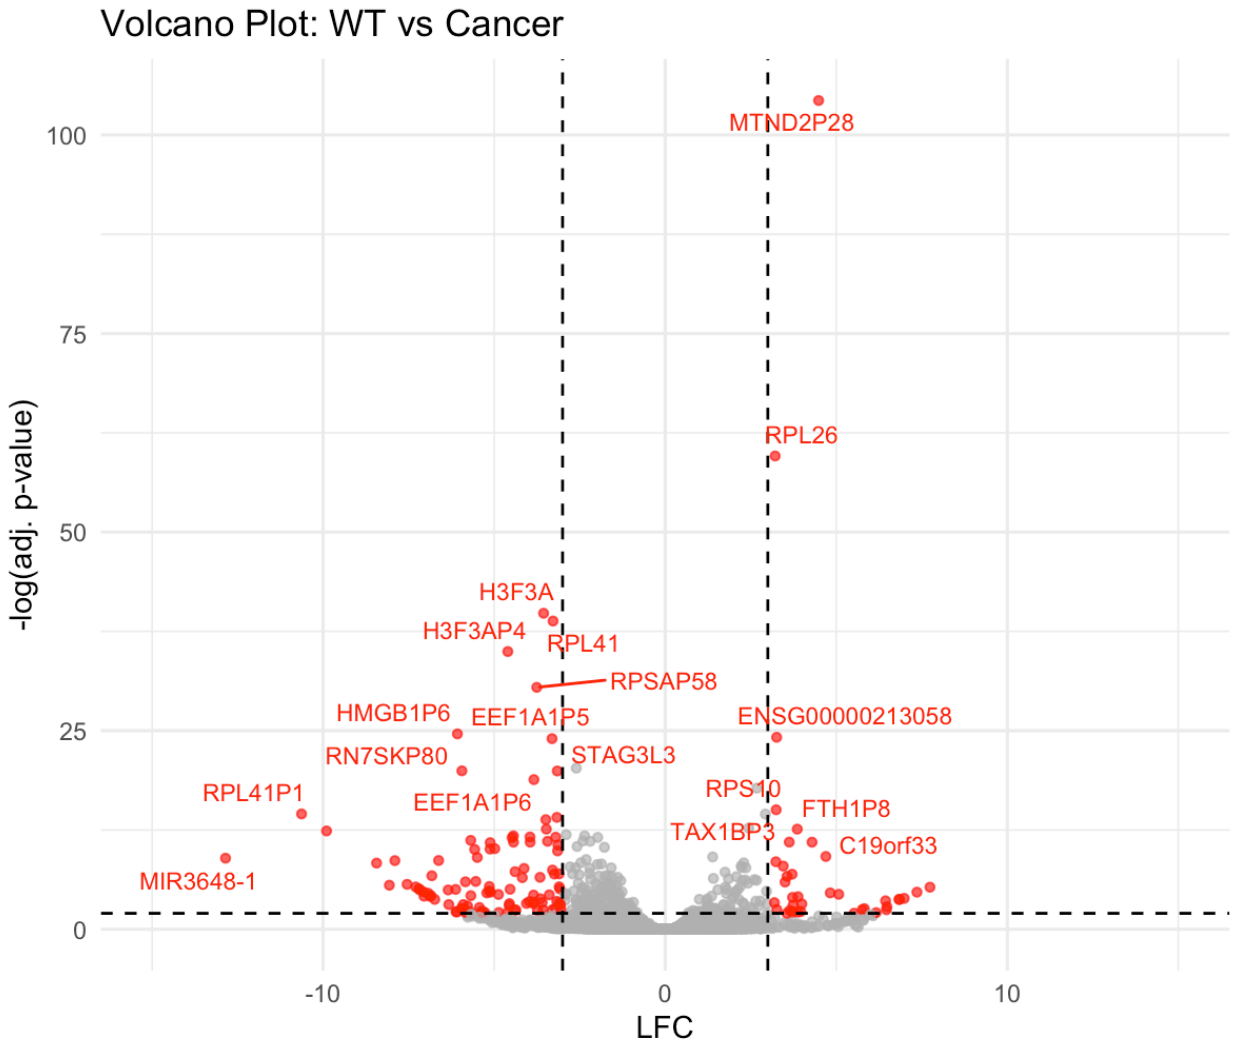

Как можно видеть, в образцах рака имеется несколько десятков генов, экспрессия которых значимо отличается от таковой в контрольных клетках (WT) (отмечены красным), есть гены с очень высокими p-value, как среди оверэкспрессированных (например, MTND2P28, RPL26), так и с пониженной экспрессией (H3F3A), на которые имеет смысл обратить более пристальное внимание.

Задание 2

Данные получены из датасета GSE63885 (GEO). Это клинические образцы пациенток с раком яичника. Экспрессия генов измерялась на одноканальном микрочипе Affymetrix Human Genome.

Для анализа дифференциальной экспрессии был выбран пакет LIMMA, поскольку данные микрочипов представляют собой непрерывные значения интенсивности, а не счётные данные RNA-seq. LIMMA использует линейные модели и empirical Bayes модерацию дисперсий, что особенно эффективно при малом числе образцов. Сравниваются две группы: pCR (полный патологический ответ на химиотерапию, n=39) и pNC (нет ответа, n=2).

Был запущен LIMMA-анализ с дизайн-матрицей, кодирующей принадлежность к группе pCR. Поскольку стандартная поправка Бенджамини–Хохберга не выявила ни одного значимого гена при adj.P.Val < 0.05, что объясняется сильным дисбалансом групп (39 vs 2), для визуализации использовался сырой p-value (P.Value < 0.05) без поправки на множественное тестирование, что следует учитывать при интерпретации результатов..

Были протестированы четыре порога |logFC|: 1, 2, 2.5, 3 (таблица limma_results.csv на гитхаб):

Порог |logFC|	Значимых генов
1	67
2	15
2.5	4
3	0

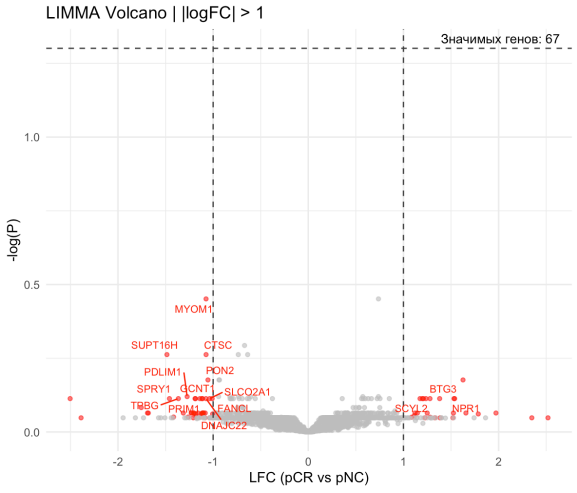

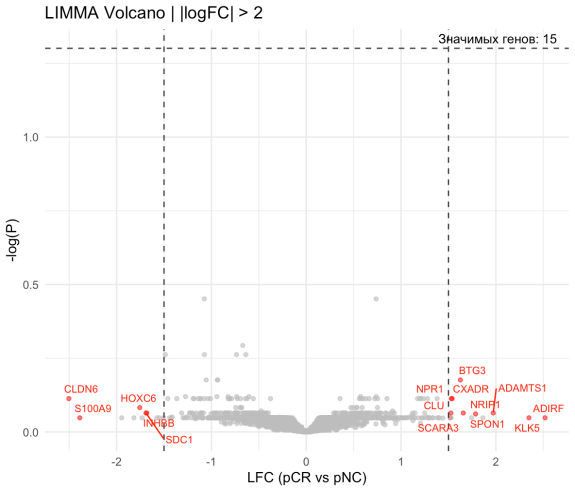

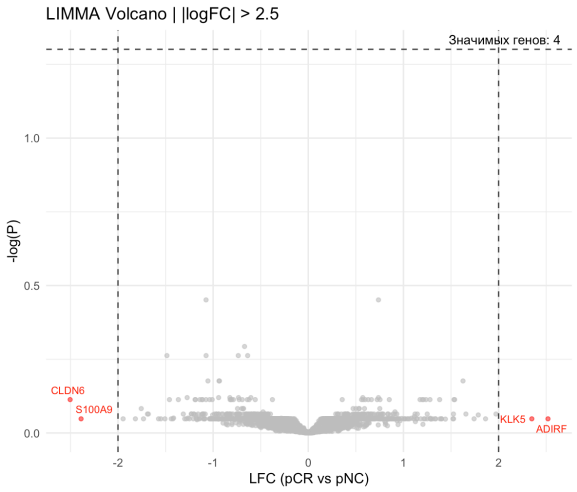

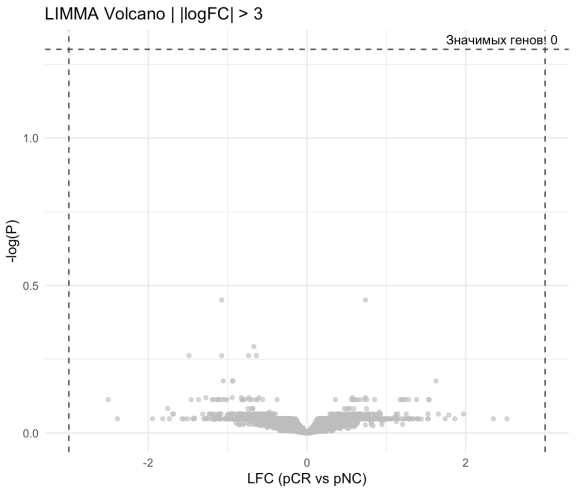

Для данного анализа оптимальным является порог |logFC| > 1. Во-первых, максимальный наблюдаемый |logFC| в данных составляет около 2.5. Пороги 2.5 и 3 отсекают почти все гены не потому, что изменения биологически незначимы, а потому что такие значения на микрочипах практически недостижимы. Во-вторых, при |logFC| > 2 остаётся 15 генов, при > 2.5 - всего 4, при > 3 - ни одного. Это слишком мало для содержательного биологического анализа. В-третьих, порог |logFC| > 1 - стандартный минимальный биологически значимый порог для данных микрочипов. При этом пороге выявляется 67 генов, что достаточно для дальнейшего функционального анализа.

Среди генов со сниженной экспрессией в pCR есть гены, связанные с ремоделированием цитоскелета и иммунным ответом (MYOM1, CTSC, SUPT16H, PDLIM1). Среди генов с повышенной экспрессией в pCR есть гены, ассоциированные с подавлением пролиферации и апоптозом (BTG3, NPR1, SCYL2), что согласуется с лучшим ответом на химиотерапию. Однако стоит помнить, что все результаты получены на основе сырого p-value. Выявленные гены следует рассматривать как предварительные кандидаты, требующие валидации на сбалансированной выборке.